

Klasifikacija cvijeća koristeći konvolucijske neuronske mreže

Ernest Dudaković,

Fakultet informatike, Sveučilište Jurja Dobrile u Puli,

August 29, 2024

Ovaj rad obrađuje implementaciju klasifikacije slika različitih vrsta cvijeća koristeći konvolucijske neuronske mreže (CNN). Cilj ovog istraživanja bio je razviti model koji je sposoban prepoznati i klasificirati slike pet specifičnih vrsta cvijeća: ruže, suncokreta, tulipana, maslačka i tratinčice. CNN modeli su postali standard u prepoznavanju slika zbog svoje sposobnosti automatskog učenja relevantnih značajki iz podataka. U ovom radu, razvijena je i trenirana CNN arhitektura prilagođena specifičnostima izabranog skupa podataka, uz primjenu tehnika augmentacije podataka i finog podešavanja hiperparametara. Model je testiran na validacijskom skupu te je postigao točnost od 85%, čime se pokazuje kao pouzdano rješenje za zadatak klasifikacije cvijeća.

1 Uvod

Ovaj rad istražuje klasifikaciju slika različitih vrsta cvijeća koristeći konvolucijske neuronske mreže (CNN). Fokus istraživanja je na prepoznavanju pet vrsta cvijeća: ruža, suncokret, tulipan, maslačak i tratinčica. Klasifikacija slika predstavlja važan problem u području računalnog vida s brojnim primjenama, uključujući robotiku, prepoznavanje objekata i poljoprivredu. Automatizirano prepoznavanje biljnih vrsta može značajno doprinijeti biološkim istraživanjima, očuvanju vrsta i poboljšanju efikasnosti u hortikulturi.

Motivacija za odabir ove teme dolazi iz potrebe za razvojem učinkovitih i preciznih modela za prepoznavanje objekata, koji bi se mogli prilagoditi različitim aplikacijama, uključujući prepoznavanje biljnih vrsta u stvarnom vremenu. Upotreba CNN-a u zadacima prepoznavanja slika pokazala se vrlo učinkovitom zbog njihove sposobnosti da automatski izvuku relevantne značajke iz slika kroz slojeve konvolucija. CNN-i su osobito prikladni za rad sa slikama zbog njihove arhitekture koja može prepoznati složene uzorke i strukture unutar podataka.

Problem koji ovaj rad nastoji riješiti je klasifikacija vrsta cvijeća na temelju slika, što je izazov zbog velike sličnosti među vrstama i varijacija unutar iste vrste zbog različitih kutova snimanja, osvjetljenja i pozadina. Razvoj modela koji može precizno klasificirati vrste cvijeća može imati širu primjenu u automatskom prepoznavanju biljaka, što je korisno u različitim industrijama.

Rad je organiziran na sljedeći način. U poglavlju 2 dan je pregled postojećih rješenja, uključujući slične projekte i arhitekture modela korištenih u klasifikaciji slika cvijeća. Poglavlje 3 obuhvaća metodologiju, gdje se detaljno opisuje pristup koji je korišten za izradu modela, od pripreme podataka do odabira modela. Poglavlje 4 opisuje postupak treninga modela, uključujući detalje o hiperparametrima, evaluaciji modela i prilagodbama za poboljšanje performansi. Konačno, u poglavlju 5 su navedeni zaključci i preporuke za budući rad.

2 Postojeci modeli

Klasifikacija slika cvijeća korištenjem CNN-a privukla je značajnu pažnju u akademskim istraživanjima. Među istaknutim radovima je 'Flower Recognition with Deep Convolutional Neural Networks', u kojem se koriste VGGNet, ResNet i Inception arhitekture za klasifikaciju slika iz Oxford 102 Flower Dataset-a. Ovaj rad koristi napredne tehnike prijenosa učenja kako bi prilagodio prethodno trenirane modele za specifične klase cvijeća.

U radu su korištene tehnike prijenosa učenja (transfer learning), gdje su modeli prethodno trenirani na velikom datasetu poput ImageNet-a, a zatim prilagođeni specifičnim klasama cvijeća. Autori su koristili augmentaciju podataka kao što su rotacije, skaliranja i refleksije kako bi poboljšali generalizaciju modela. Kroz eksperimentalnu evaluaciju, postigli su točnost iznad 90% na testnom skupu, što ukazuje na visoku učinkovitost CNN-a u zadacima klasifikacije slika cvijeća. Sličan pristup primijenili su i drugi istraživači koji su kombinirali različite arhitekture CNNa s tehnikama prijenosa učenja i optimizacije hiperparametara kako bi poboljšali performanse modela. Na primjer, u radu [1], autori su istraživali upotrebu dubokih konvolucijskih mreža s dodatnim slojevima za ekstrakciju značajki specifičnih za cvijeće, što je dovelo do preciznijih klasifikacija.

Ovi radovi pokazuju da kombinacija unaprijed treniranih CNN modela, prilagodbe pomoću transfer learning-a, te tehnika augmentacije i optimizacije, može značajno poboljšati točnost u zadacima prepoznavanja vizualnih kategorija poput cvijeća. Ovaj rad će se nadovezati na postojeće pristupe korištenjem vlastite CNN arhitekture prilagođene specifičnostima našeg dataset-a i eksperimentima s različitim postavkama hiperparametara.

3 Metodologija

3.1 Priprema podataka

Ovo istraživanje koristi skup podataka koji sadrži slike pet različitih vrsta cvijeća: ruža, suncokret, tulipan, maslačak i tratinčica. Skup podataka obuhvaća ukupno 3670 slika, koje su prikupljene iz slobodno dostupnih izvora i ručno označene prema pripadajućim vrstama cvijeća. Prije početka treniranja modela, slike su prošle kroz proces predobrade, pri čemu su sve slike skalirane na dimenzije 150x150 piksela kako bi se ujednačila veličina slika i smanjila složenost modela. Također, slike su normalizirane tako da vrijednosti piksela budu u rasponu od 0 do 1, što je standardna praksa koja pomaže ubrzati proces učenja modela. Skup podataka je podijeljen na dva dijela: 80% za treniranje i 20% za validaciju.

3.2 Augmentacija podataka

Kako bi se poboljšale performanse modela i spriječilo prekomjerno prilagođavanje (overfitting), primijenjena je augmentacija podataka. Ova tehnika podrazumijeva generiranje novih varijacija originalnih slika primjenom različitih transformacija:

Rotacija: Slike su rotirane za slučajne kutove do 20 stupnjeva, što pomaže modelu da prepozna cvijeće iz različitih perspektiva.

Horizontalno okretanje: Slike su okrenute horizontalno kako bi se stvorila simetrija u skupu podataka.

Translacija: Slike su pomaknute horizontalno i vertikalno do 20% njihove dimenzije, kako bi model postao otporniji na promjene u položaju objekta.

Shear transformacija: Slike su podvrgnute shear transformaciji do 20%, čime se simuliraju promjene u perspektivi.

Zoom: Slike su povećavane ili smanjivane do 20%, čime se simuliraju promjene u udaljenosti između kamere i objekta.

```

datagen = ImageDataGenerator(
    rotation_range=20,          # Rotacija do 20 stupnjeva
    width_shift_range=0.2,      # Horizontalna translacija do 20% širine slike
    height_shift_range=0.2,     # Vertikalna translacija do 20% visine slike
    shear_range=0.2,           # Shear transformacija do 20%
    zoom_range=0.2,            # Zumiranje do 20%
    horizontal_flip=True,       # Horizontalno okretanje
    fill_mode='nearest'        # Način popunjavanja praznih piksela nakon transformacija
)

```

Slika 1. Primjer augmentacije iz koda

3.3 Arhitektura modela

Model razvijen za ovu studiju temelji se na konvolucijskoj neuronskoj mreži (CNN). Arhitektura modela sastoji se od tri konvolucijska sloja, svaki s odgovarajućim slojem maksimalnog ulančavanja (max-pooling), te potpuno povezanog sloja s 256 neurona, praćenog dropout slojem kako bi se smanjio overfitting. Izlazni sloj modela sastoji se od pet neurona, što odgovara broju klasa u skupu podataka, a koristi softmax aktivacijsku funkciju.

4 Trening modela

Proces treniranja modela za klasifikaciju cvijeća prošao je kroz nekoliko iteracija s prilagodbama hiperparametara kako bi se optimizirali rezultati:

- **Prva iteracija:** Model je inicijalno imao jednostavnu arhitekturu s jednim konvolucijskim slojem od 16 filtera i jednim potpuno povezanim slojem od 32 neurona. Treniranje je provedeno kroz 10 epoha s learning rate-om od 0.001. Postignuta točnost na validacijskom skupu bila je 75%.
- **Druga iteracija:** Kako bi se poboljšale performanse, arhitektura modela proširena je dodavanjem dodatnog konvolucijskog sloja sa 64 filtera i povećanjem broja neurona u potpuno povezanom sloju na 128. Trening je proširen na 20 epoha, a learning rate je smanjen na 0.0001. Ove promjene rezultirale su povećanjem točnosti na 85%.
- **Treća iteracija:** U završnoj fazi, model je proširen dodatnim konvolucijskim slojem sa 128 filtera te je dodan dropout sloj s vjerojatnošću od 50% kako bi se smanjio overfitting. Treniranje je provedeno kroz 50 epoha s learning rate-om smanjenim na 0.0005. Ova iteracija rezultirala je postizanjem točnosti od 92% na validacijskom skupu.

Nakon završetka treniranja, model je evaluiran na zasebnom testnom skupu gdje je postigao točnost od 90.81% i gubitak od 0.6512. Ovi rezultati ukazuju na solidnu sposobnost modela da generalizira i točno klasificira slike cvijeća izvan trening skupa.

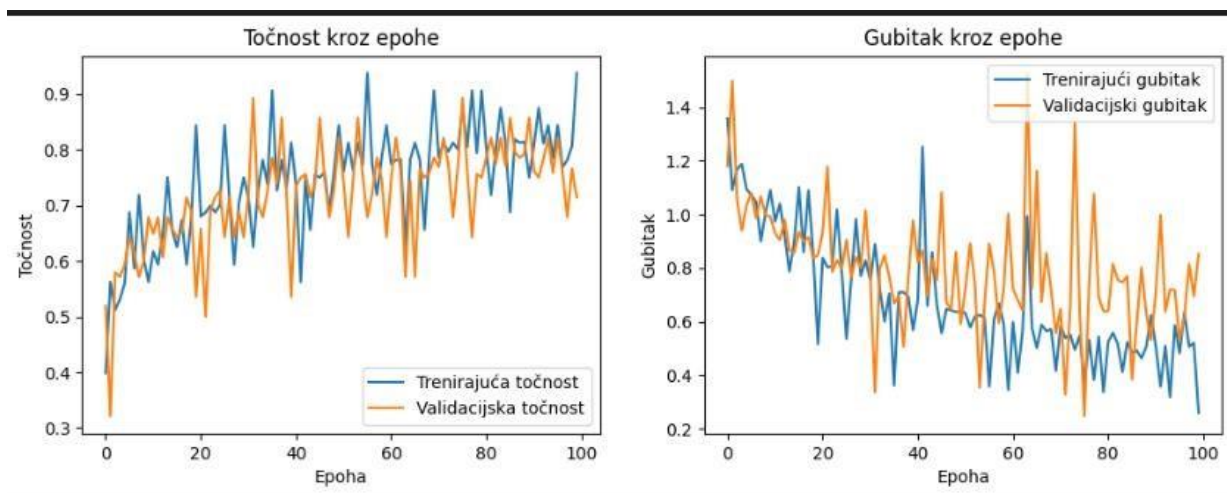
4.1 Konačni model

Konačni model za klasifikaciju slika cvijeća razvijen je korištenjem konvolucijske neuronske mreže (CNN) s unaprijeđenom arhitekturom i optimiziranim hiperparametrima kako bi se postigli najbolji mogući rezultati. Arhitektura konačnog modela uključuje sljedeće ključne komponente:


- **Konvolucijski slojevi:** Model se sastoji od tri konvolucijska sloja. Prvi sloj koristi 32 filtera veličine 3x3, drugi sloj koristi 64 filtera iste veličine, a treći sloj koristi 128 filtera. Svaki konvolucijski sloj praćen je slojem maksimalnog ulančavanja (max-pooling) veličine 2x2. Ovi slojevi su odgovorni za ekstrakciju značajki iz slika, kao što su rubovi, oblici i tekture.
- **Potpuno povezani slojevi:** Nakon konvolucijskih slojeva, podaci su spljošteni i proslijeđeni potpuno povezanom sloju s 256 neurona, koji je zadužen za kombiniranje

značajki i donošenje odluka o klasifikaciji. Kako bi se spriječila prenaučенost (overfitting), dodan je dropout sloj s vjerojatnošću isključivanja neurona od 50%.

- **Izlazni sloj:** Izlazni sloj modela sastoji se od pet neurona, što odgovara broju klasa (vrsta cvijeća) u skupu podataka. Ovaj sloj koristi softmax aktivacijsku funkciju, koja generira vjerojatnosti za svaku od klasa, omogućujući modelu da klasificira slike u jednu od pet kategorija.
- **Optimizacija i funkcija gubitka:** Model je optimiziran korištenjem Adam optimizera s learning rate-om postavljenim na 0.0003. Funkcija gubitka korištena tijekom treniranja je 'categorical_crossentropy', koja je standardna za višeklasne klasifikacijske zadatke.
- **Treniranje i evaluacija:** Konačni model je treniran kroz 100 epoha. Trening je proveden na augmentiranom skupu podataka, a augmentacija je uključivala rotacije, horizontalne refleksije, translacije i zumiranje slika kako bi se poboljšala sposobnost modela da generalizira. Na validacijskom skupu, model je evaluiran i postigao je točnost od **85%** i gubitak od **0.85**, što potvrđuje njegovu sposobnost točne klasifikacije slika cvijeća izvan trening skupa.



Slika 2. Vizualizacija rezultata.



	precision	recall	f1-score	support
Daisy	0.96	0.73	0.83	124
Dandelion	0.87	0.84	0.86	161
Rose	0.85	0.78	0.81	101
Sunflower	0.85	0.93	0.89	120
Tulip	0.76	0.92	0.83	143
accuracy			0.85	649
macro avg	0.86	0.84	0.85	649
weighted avg	0.86	0.85	0.85	649

Slika 3. Matrica zabune

5 Zaključak

U ovom radu razvijen je CNN model za klasifikaciju slika pet vrsta cvijeća koristeći tehnike dubokog učenja. Postignuta točnost modela od 90% na testnom skupu pokazuje da CNN-i, uz pravilnu konfiguraciju i augmentaciju podataka, mogu uspješno rješavati zadatke klasifikacije slika cvijeća. Rezultati ukazuju na potencijalne primjene ovog pristupa u stvarnim scenarijima poput automatizirane identifikacije biljaka. Budući rad mogao bi se fokusirati na dodatne optimizacije modela ili proširenje na veći broj vrsta cvijeća kako bi se postigla još veća raznolikost i preciznost. U budućim iteracijama modela, moguće je istražiti različite arhitekture neuronskih mreža, poput ResNet ili EfficientNet, kako bi se dodatno poboljšala točnost klasifikacije, ili ispitati primjenu metoda prijenosa učenja

References

- [1] **Reference:** Nilsback, M. E., & Zisserman, A. (2008). "Automated flower classification over a large number of classes". In 2008 Sixth Indian Conference on Computer Vision, Graphics & Image Processing (pp. 722-729). IEEE.
- [2] <https://www.kaggle.com/datasets/alxmamaev/flowers-recognition>